
SIEM 로그 기반

이메일 외부 유출 위험 사용자 탐지 및 위험 스코어링

통합기획서 - 대시보드 예시 및 제공 로그 데이터 정의 부록 포함

문서 구성	본편 + 부록 A 제공 로그 데이터 상세 정의
분석 범위	2010-01-02 ~ 2011-05-17 / 1,000개 계정
해석 원칙	실제 유출 확정이 아닌 조사 우선순위 제공

1. 프로젝트 개요

프로젝트명

SIEM 로그 기반 이메일 외부 유출 위험 사용자 탐지 및 위험 스코어링

목표 및 범위

본 프로젝트는 이메일 로그와 직원 계정 정보(LDAP)를 활용해 사용자의 평소 행동에서 벗어난 외부 전송을 탐지하고, 위험점수와 조사 우선순위를 제공한다.

구분	내용
목표	외부 전송 이상징후를 탐지해 조사 대상의 우선순위를 제시한다.
분석 데이터	직원 계정 정보(LDAP), 장치, 이메일, 파일, 웹, 로그인, 성격 특성 데이터
분석 단위	사용자별 하루(User×Day) 이메일 활동
분석 방법	사용자의 평소 행동과 현재 행동의 차이를 계산하고 복합 이상행동을 탐지한다.
결과물	위험 사용자 순위, 위험점수, 위험등급, 점수 산정 근거
해석 범위	실제 정보유출자를 확정하지 않고 조사가 필요한 사용자를 선별한다.
확장 범위	장치·파일·웹·로그온 활동을 결합한 다중 로그 분석으로 확장한다.

2. 추진 배경

실제 정보유출 사례

NIA 사례에서는 한 직원이 2022년부터 약 3년간 기관 이메일로 외부 업체 관계자에게 비공개 자료를 380회 전달한 것으로 알려졌다. 반복적인 외부 전송이 장기간 탐지되지 않았다는 점에서 사용자별 이메일 행동을 지속적으로 분석할 필요성을 확인했다.

본 프로젝트는 이러한 사례를 참고해 장기간 반복되는 외부 이메일 전송, 새로운 외부 수신자, 첨부파일 증가, 평소보다 큰 메시지 및 비정상 시간대 활동을 탐지 대상으로 설정한다.

다만 제공된 로그만으로 실제 자료의 기밀성, 전달 성공 여부 또는 사용자의 악의성을 확인할 수 없다. 따라서 분석 결과는 정보유출 확정이 아니라 조사 대상의 우선순위를 정하는 근거로 활용한다.

주제 선정 이유

- 평소와 다른 수신자, 전송량, 첨부파일 사용과 반복 전송을 분석해 정보유출 징후를 조기에 탐지할 수 있다.
- 제공된 이메일 로그에는 사용자, PC, 발신·수신 주소, 시간, 메시지 크기, 첨부파일 및 BCC 정보가 포함돼 있다.
- 이메일 활동 전후의 파일 로그를 연결하면 단일 이메일만으로 확인하기 어려운 복합 행동을 탐지할 수 있다.
- 위험점수와 점수 산정 근거를 함께 제공하면 보안 담당자가 조사 대상을 효과적으로 선별할 수 있다.

3. 데이터 분석 근거

본 프로젝트는 이메일·직원 계정 정보·파일 로그를 결합해 사용자의 평소 행동에서 벗어난 외부 전송과 그 선행 행동을 탐지하고, 조사 우선순위를 제시한다.

제공 로그와 핵심 데이터

데이터	핵심 항목	활용 목적
이메일	시간, 사용자, PC, 발신·수신 주소, 메시지 크기, 첨부 수	외부 수신자, 첨부, 전송 규모, 시간대 및 신규 목적지 분석
직원 계정 정보(LDAP)	사용자 ID, 회사 이메일, 직무, 조직	이메일 발신자 확인, 회사 내부·외부 주소 구분
파일	시간, 사용자, PC, 파일명	외부메일 발생 전 파일 활동 급증 탐지
장치	시간, 사용자, PC, 연결·해제 활동	이동식 장치 사용과 파일·메일 활동의 연관성 검토
로그온	시간, 사용자, PC, 로그인·로그오프	사용자 세션 및 평소와 다른 활동시간 검토
웹	시간, 사용자, PC, URL	새로운 외부 도메인 및 웹 활동 변화 검토
성격 특성	사용자 ID, OCEAN 점수	행동 분석의 보조 속성으로만 검토

각 로그의 컬럼, 데이터 형식, 연결 방법과 해석 시 주의사항은 부록 A의 제공 로그 데이터 상세 정의를 참고한다.

데이터 정제 기준

정제 항목	적용 기준
사용자 컬럼명	활동 로그의 사용자 식별 컬럼을 user로 통일
날짜·시간 형식	날짜를 YYYY-MM-DDTHH:MM:SS 형식으로 통일
이메일 주소	앞뒤 공백을 제거하고 영문 대소문자를 통일
복수 수신자	to, cc, bcc를 세미콜론 기준으로 분리
내부 도메인	주소 도메인이 정확히 dtaa.com일 때 내부로 분류
발신자 확인	이메일 로그의 user와 from이 해당 월 LDAP의 사용자 및 회사 이메일과 모두 일치하는지 확인
분석 단위	이벤트를 사용자별 하루(User×Day) 단위로 집계

분석 모집단

원본 이메일 1,314,400건 중 이메일 기록의 user와 발신 주소가 당시 직원 계정 정보의 사용자 및 회사 이메일과 모두 일치한 815,250건을 분석 대상으로 사용한다.

이 가운데 외부 수신자가 포함된 이벤트는 136,519건으로, 발신 검증 이벤트의 16.75%다. 분석 대상 고유 계정은 1,000개이며, 사용자별 하루 분석 레코드는 289,783건이다.

외부 발송 후보 = 이메일 기록의 사용자·발신 주소가 직원 계정 정보와 일치하고 회사 외부 수신자가 1명 이상 존재하는 이벤트

외부 주소가 포함됐다는 사실만으로 정보유출이나 악성 행위를 확정하지 않는다.

개인별 평소 행동과 비교

사용자마다 담당 업무와 평소 이메일 사용량이 다르므로 모든 사용자에게 동일한 절대 기준을 적용하지 않는다. 각 사용자의 현재 날짜 이전 최대 30개 관찰일을 기준선으로 설정하고 현재 행동과 비교한다. Robust Z-score가 클수록 현재 행동이 해당 사용자의 평소 행동보다 크게 증가했다는 의미다. 현재 날짜 이후의 기록은 과거 기준선에 포함하지 않는다.

주요 분석지표

분석지표	계산·판단 기준	분석 목적
외부메일 수	외부 수신자가 포함된 이메일 수	외부 전송 활동량 확인
외부 수신자 수	to, cc, bcc의 외부 주소 수	전달 범위 확인
외부 도메인 수	외부 주소의 고유 도메인 수	전달 대상 다양성 확인
신규 외부 수신자	해당 사용자에게 과거에 없었던 외부 주소	새로운 전달 경로 탐지
신규 외부 도메인	해당 사용자에게 과거에 없었던 외부 도메인	새로운 조직·서비스 탐지

분석지표	계산·판단 기준	분석 목적
외부 첨부메일	외부 수신자와 첨부파일이 함께 존재하는 이메일	자료 전달 가능성 확인
메시지 크기 변화	사용자 과거 기준 대비 메시지 크기 증가	평소보다 큰 자료 전송 탐지
외부 BCC	외부 주소가 BCC에 포함된 이메일	수신자 비공개 전송 확인
비정상 시간대	주말 또는 평일 08시 이전·19시 이후	근무시간 외 활동 탐지
파일 활동 급증	과거 기준 대비 파일 이벤트 증가	이메일 전 자료 취급 증가 탐지
반복 외부 전송	동일 주 또는 여러 주에 걸친 외부 활동	장기·반복 전송 탐지

분석 결과의 개발 적용

분석 결과	확인 내용	개발 적용
과거 기록 확보	전체 분석일 중 89.66%는 사용자별 과거 기록이 30일 이상 존재	개인 기준선 기반 비교
비정상 시간대 활동	6,761개의 사용자×일 기록에서 평소와 다른 시간대 활동 확인	개인의 평소 시간대와 비교
파일 활동 급증	과거 30일 대비 파일 활동 Robust Z-score가 3 이상인 날 3,907건	이메일 전 파일 활동을 선행 신호로 활용
파일-메일 복합행동	파일 급증 후 외부 첨부메일과 크기 증가 또는 복수 첨부 이어진 후보 95건·51개 계정	우선 조사 대상 선정
외부 첨부·크기 증가	첨부 수, 메시지 크기와 수신자 수가 함께 증가한 날짜 확인	자료량과 전달 범위가 증가한 사례 탐지
장기 반복 활동	여러 주에 걸쳐 외부 이메일을 반복한 사용자 확인	NIA 사례와 유사한 장기 반복 행동 탐지

데이터 제약사항

제약	대응 원칙
이메일에 발송·수신 구분 항목이 없음	user와 from이 LDAP의 사용자·회사 이메일과 일치하는 경우만 발신 후보로 사용
메시지 크기의 단위와 첨부 포함 여부가 불명확	절대 전송량이 아니라 사용자 과거 행동 대비 변화로 해석
파일 로그에 작업 종류·크기·복사 방향이 없음	파일 활동과 이메일의 시간적 선후관계만 제시
근무표·승인 외부 도메인 정보가 없음	비근무시간과 신규 목적지는 보조 지표로 사용
실제 유출 여부를 나타내는 정답 데이터가 없음	정확도를 주장하지 않고 탐지 근거와 조사 우선순위를 제시
파일 해시와 메일 첨부파일 정보가 없음	파일 이벤트와 첨부파일의 동일성을 확정하지 않음
로그 시간대 정보가 없음	특정 국가·지역의 시간대로 임의 해석하지 않음

4. 개발 계획

핵심 개발 방향은 개인의 평소 행동과 현재 행동을 비교하고 여러 로그의 발생 순서를 연결해, 이해하기 쉬운 위험점수와 조사 근거를 제공하는 것이다.

전체 분석 흐름




그림 1. 이메일 외부 유출 위험 사용자 탐지 및 위험점수 산정 흐름

분석의 핵심 지표는 ① 평소와 다른 시간대의 활동, ② 외부메일 발송 급증, ③ 외부 첨부·메시지 크기·수신자 증가, ④ 파일 활동 급증이다. 특히 파일 활동 급증 → 2시간 이내 외부 첨부메일 → 평소보다 큰 메일 또는 첨부 2개 이상의 흐름을 주요 위험행동 후보로 탐지한다.

기술 스택

구분	기술	용도
데이터 저장·조회	SQLite, CSV	로그 조회 및 중간 분석 결과 관리
데이터 처리·분석	Python, Pandas, NumPy	주소 파싱, 데이터 연결, 사용자×일 집계
통계 기반 탐지	개인 기준선, Robust Z-score	평소보다 크게 증가한 행동 탐지
조건 기반 탐지	Rule, Novelty, Sequence	신규 목적지, 반복 행동 및 파일-메일 순서 탐지
비교 모델	Isolation Forest	여러 행동이 동시에 달라진 사례의 추가 탐색
결과 제공	Streamlit 또는 Jupyter	위험 사용자 순위 및 사용자 상세 근거 제공
협업·문서화	GitHub, Notion	코드 버전 관리, 지표 정의 및 분석 기준 공유

5. 결과 제공 화면

분석 결과는 위험 사용자를 우선적으로 확인하고, 각 사용자의 위험점수 산정 근거를 추적할 수 있는 대시보드로 제공한다.

위험 사용자 순위

위험점수 기반 조사 우선순위를 제공하는 사용자 Ranking 화면

사용자×일 단위의 위험점수와 위험등급을 기준으로 조사 대상을 정렬한다. 외부메일, 외부 수신자, 신규 수신자, 첨부메일, 메시지 크기, 외부 BCC 및 비정상 시간대 활동 등 주요 지표를 함께 표시하여 사용자 간 위험 수준을 비교할 수 있도록 한다.

☰ 위험 사용자 순위

총 5건

이상징지 기반 위험 점수가 높은 사용자 순위입니다.

계정	날짜	발신확인 메일	외부메일	외부수신자	고유외부 수신자	신규수신자	첨부메일	첨부수	Size합계	외부 BCC	비정상시간 메일	위험점수	위험등급
WIQ0567	2010-12-21	11	5	8	6	2	3	5	198510	2	1	89	CRITICAL
GTD0219	2010-06-01	12	5	7	5	1	4	6	182430	1	0	82	HIGH
RDT0424	2010-06-28	9	5	5	4	0	3	3	141220	0	1	74	HIGH
KMS0391	2010-08-17	8	4	6	4	1	2	4	105330	1	0	68	MEDIUM
LMP7820	2010-11-03	7	3	4	3	1	1	2	92310	0	0	52	MEDIUM

그림 2. 위험점수 및 위험등급 기반 사용자 조사 우선순위 화면

선택 사용자 위험 프로필

위험점수 산정 근거를 설명하는 사용자 상세 화면

선택한 사용자의 최종 위험점수와 위험등급, 이상지표별 점수 및 주요 탐지 근거를 제공한다. 이를 통해 해당 사용자가 어떤 행동지표 때문에 고위험 후보로 분류됐는지 확인하고 관련 원본 이벤트 조사로 연결할 수 있다.



그림 3. 선택 사용자의 위험점수와 주요 탐지 근거 상세 화면

대시보드 예시 이미지에 표시된 사용자, 점수 및 수치는 화면 구성을 설명하기 위한 예시이며 실제 분석 결과로 단정하지 않는다.

6. 역할 분담

3명이 데이터 준비부터 결과 검증까지 병렬로 진행하되, 지표 정의와 위험점수 산정 기준은 공동으로 검토한다.

담당자	핵심 역할	주요 업무
권순성	기획·검증	프로젝트 범위와 일정 관리, 분석 기준 및 위험 시나리오 검증, 결과물과 발표자료 통합
김 솔	데이터·지표	이메일·직원 계정 정보 정리, 사용자별 하루 행동지표 생성, 개인별 평소 행동 기준 개발
김현수	점수·시각화	파일-메일 발생 순서 분석, 위험점수와 조사 우선순위 산정, 대시보드 및 결과 화면 구현

7. 2주간 WBS 개발 일정

기간	핵심 목표	주요 결과물
1주차	데이터 정리, 행동지표 생성, 개인별 평소 행동 기준과 탐지 규칙 구현	정제 데이터, 사용자×일 행동지표, 개인 기준선, 평소 대비 변화값, 규칙 기반 탐지 결과
2주차	파일-메일 발생 순서 분석, 위험점수 및 대시보드 구현, 결과 검증과 발표 준비	위험 사용자 순위, 선택 사용자 위험 프로필, 점수 산정 근거, 원본 이벤트 조회 화면, 검증 결과, 발표자료

1주차 세부 작업

작업	담당	산출물
로그 구조 및 데이터 품질 확인	김 솔	데이터 품질검사 결과
이메일·LDAP 데이터 정제 및 연결	김 솔	발신 검증 이메일 데이터
사용자×일 행동지표 생성	김 솔	사용자×일 행동지표 테이블
위험지표와 임계값 정의	권순성·김 솔	위험지표 정의서
개인별 평소 행동 기준 구현	김 솔	Robust Z-score 기반 기준선
분석 시나리오 검토	권순성	위험행동 시나리오 및 검증 기준

2주차 세부 작업

작업	담당	산출물
파일-메일 발생 순서 분석	김현수	복합행동 탐지 결과
위험점수와 위험등급 구현	김현수	사용자×일 위험점수
위험 사용자 Ranking 화면 구현	김현수	위험 사용자 순위 대시보드
선택 사용자 상세 화면 구현	김현수	위험점수 산정 근거 화면
결과 검증 및 사례 점검	권순성·김 솔·김현수	검증 결과 및 대표 탐지 사례
최종 문서와 발표자료 통합	권순성	최종 보고서 및 발표자료

부록 A. 제공 로그 데이터 상세 정의

본 부록은 제공된 데이터 사전 v0.2의 내용을 통합기획서에 편입한 것이다. 원문에 포함된 분석 지시는 실행 명령이 아니라 데이터 정의 및 해석상 주의사항으로만 반영했다.

작성일: 2026-09-14 분석 목적: 보안 회사의 데이터분석 프로젝트에서 사용할 데이터 구조와 컬럼 의미 파악

1. 분석 범위와 해석 기준

device.csv, email.csv, file.csv, http.csv, logon.csv, psychometric.csv, LDAP/2009-12.csv의 **7개 파일을 분석했다.

CSV 파서로 전체 행을 읽어 컬럼 수, 빈 값, 이벤트 ID 중복, 날짜 범위·파싱, 활동 종류, 주요 숫자 범위 및 사용자 연결 관계를 확인했다. 내용 필드의 의미는 헤더와 대표 값의 구조를 함께 검토했다.

이 데이터는 사용자 활동 로그 5종과 직원 속성 데이터 2종으로 구성된다.

2. 파일별 개요

파일명	데이터 성격 / 한 행의 의미	데이터 행 수	컬럼 수	고유 사용자 수	확인된 기간 또는 기준
device.csv	이동식 장치 연결·해제 이벤트 1건	405,380	5	265	2010-01-02 07:21:06 ~ 2011-05-16 23:22:34
email.csv	사용자·PC에 연결된 이메일 이벤트 1건	1,314,400	11	1,000	2010-01-02 07:11:45 ~ 2011-05-16 21:16:26
file.csv	사용자·PC에서 발생한 파일 관련 이벤트 1건	445,581	6	264	2010-01-02 07:23:14 ~ 2011-05-16 23:22:34
http.csv	사용자·PC의 웹 URL 접근 이벤트 1건	1,422,900	6	1,000	2010-01-02 07:14:28 ~ 2011-05-16 21:07:23
logon.csv	PC 로그인·로그오프 이벤트 1건	854,859	5	1,000	2010-01-02 06:49:00 ~ 2011-05-17 06:43:35
psychometric.csv	직원 1명의 성격 특성 점수	1,000	7	1,000	측정일 컬럼 없음
LDAP/2009-12.csv	직원 1명의 계정·조직 정보	1,000	9	1,000	파일명상 2009년 12월 스냅샷

기간은 제공된 파일에 존재하는 이벤트의 최솟값·최댓값이다. 이 기간의 모든 실제 행위가 빠짐없이 수집되었다는 뜻은 아니다. 특히 일부 로그에 사용자가 없다는 사실만으로 그 사용자가 해당 행위를 전혀 하지 않았다고 단정할 수 없다.

3. 활동 로그의 공통 컬럼

아래 4개 컬럼은 device.csv, email.csv, file.csv, http.csv, logon.csv에 공통으로 존재한다.

컬럼명	권장 자료형	컬럼 의미	확인 사항 및 분석 시 주의점
id	문자열	개별 로그 이벤트를 식별하는 ID	종괄호와 하이픈을 포함하는 식별자 형태. 각 파일 내부의 중복은 0건이다. 표준 UUID 형식으로 단정하지 않는다. 파일 간 연결 키로 사용하지 말고, 통합 로그에서는 source_file과 함께 관리한다. 파일 간 ID 중복 여부는 이번 검사에 포함하지 않았다.
date	날짜·시간	이벤트 발생 시각으로 해석	원본은 MM/DD/YYYY HH:mm:ss. 예: 01/02/2010은 2010년 1월 2일. 시간대·UTC 오프셋 정보가 없으므로 한국 시간이나 UTC로 임의 해석하지 않는다.
user	문자열	이벤트에 연결된 사용자 계정 ID	ABC0001 같은 형태. LDAP 및 심리측정 데이터의 user_id와 연결된다. 계정 ID에 포함된 숫자의 앞자리 0을 보존한다. 이메일의 경우 from 주소와 동일한 개념으로 취급하지 않는다.
pc	문자열	이벤트가 발생한 PC·단말 식별자	PC-0001 같은 형태. IP 주소나 장치 소유자 ID가 아니다. 사용자와 PC가 항상 일대일이라고 가정하지 않는다.

4. 파일별 컬럼 정의

4.1. device.csv — 이동식 장치 연결·해제 로그

의미: 사용자가 PC에 이동식 장치를 연결하거나 해제한 기록으로 해석한다. USB 저장장치 사용 패턴을 살펴보는 데 적합하지만, 장치 종류나 장치 고유 ID 자체는 없다.

컬럼명	권장 자료형	컬럼별 의미	값의 형태 / 확인 사항
id	문자열	장치 연결·해제 이벤트 ID	파일 내부 중복 없음
date	날짜·시간	연결 또는 해제가 기록된 시각	MM/DD/YYYY HH:mm:ss
user	문자열	해당 장치 이벤트에 연결된 사용자	고유 사용자 265명
pc	문자열	장치가 연결·해제된 PC	고유 PC 971대
activity	범주형 문자열	장치에 대해 수행된 행위	Connect: 연결, 203,339건 / Disconnect: 해제, 202,041건

분석 시 활용: 사용자별 연결 빈도, 근무시간 외 사용, 평소와 다른 PC에서의 연결, 파일 이벤트와의 시간적 연관성.

해석상 주의: 장치 일련번호·용량·전송량은 없다. Connect는 데이터 복사 완료를 뜻하지 않는다. 연결과 해제의 총건수가 다르므로 두 행을 기계적으로 짝지어 사용시간을 계산해서는 안 된다. user·pc·시간 순서를 기준으로 누락·중첩 상황을 처리해야 한다.

4.2. email.csv — 이메일 활동 로그

의미: 이메일 주소 관계, 크기, 첨부 개수, 내용 특성을 기록한 데이터다. 현재 스키마에는 발송·수신·열람을 구분하는 activity 컬럼이 없으므로 각 행의 정확한 수집 방향은 확인이 필요하다.

컬럼명	권장 자료형	컬럼별 의미	값의 형태 / 확인 사항
id	문자열	이메일 이벤트 ID	파일 내부 중복 없음. 메일 서버의 RFC Message-ID와 동일하다고 단정할 수 없음
date	날짜·시간	이메일 이벤트가 기록된 시각	발송·수신·수집 중 어느 시각인지는 추가 명세 필요
user	문자열	이메일 활동에 연결된 사용자 계정	고유 사용자 1,000명. from과 별개의 필드
pc	문자열	해당 이메일 활동이 기록된 PC	고유 PC 1,000대
to	문자열 → 주소 목록	주 수신자 이메일 주소	여러 주소는 ;로 구분. 빈 값 없음
cc	문자열 → 주소 목록, 빈 값 허용	참조 수신자 이메일 주소. CC는 Carbon Copy	여러 주소는 ;로 구분. 빈 값 808,452건
bcc	문자열 → 주소 목록, 빈 값 허용	숨은 참조 수신자 이메일 주소. BCC는 Blind Carbon Copy	여러 주소는 ;로 구분. 빈 값 1,105,790건
from	문자열	이메일의 발신 주소	사내 도메인과 외부 도메인이 모두 관찰됨. 세미콜론으로 구분된 다중 주소는 관찰되지 않음
size	정수	이메일 메시지의 크기를 나타내는 수치로 해석	6,241~129,659. 바이트 단위로 추정하되, 정확한 단위와 첨부 포함 여부는 제공 파일만으로 확정 불가
attachments	정수	첨부파일 개수로 해석	0~9. 0은 첨부 없음으로 해석하며 결측치와 다름. 파일명·파일 크기 목록이 아님
content	문자열	이메일 내용의 텍스트·주제 키워드 표현	대표 행은 공백으로 구분된 단어 나열 형태. 원문 본문 전체, 제목 또는 제목·본문의 결합이라고 단정할 수 없음

확인한 데이터 특성

- 빈 cc는 61.51%, 빈 bcc는 84.13%다. 참조·숨은 참조가 없는 경우로 해석할 수 있으므로, 빈 값을 일괄 오류로 처리하지 않는다.
- 복수 주소가 있는 행은 to 529,534건, cc 135,661건, bcc 11,583건이다. 수신자 수·외부 도메인 여부는 CSV 행을 먼저 파싱한 뒤 각 필드를 ;로 분리해서 계산한다.

- from과 해당 user의 LDAP 등록 이메일을 대소문자 구분 없이 비교하면, 819,522건은 일치하고 494,878건(37.65%)은 다르다. 따라서 user를 언제나 from 주소의 소유자로 간주하면 안 된다. 이 불일치만으로 수신 메일, 개인 메일 사용 또는 위조라고 단정할 수는 없다.
- attachments=0은 1,032,820건이다. 메시지 크기를 첨부파일 크기로 해석하거나, size와 첨부 개수를 같은 의미의 변수로 취급하지 않는다.

분석 시 활용: 수신자 수, 사내·외 주소 관계, 숨은 참조 사용 패턴, 첨부 개수, 사용자별 메시지 크기 변화. 발송·수신 방향을 검증하기 전에는 외부 주소가 포함된 행 전체를 ‘외부로 반출한 메일’로 집계하지 않는다.

4.3. file.csv — 파일 관련 행위 로그

의미: 사용자와 PC를 기준으로 파일명 및 내용 표현이 기록된 이벤트다.

컬럼명	권장 자료형	컬럼별 의미	값의 형태 / 확인 사항
id	문자열	파일 관련 이벤트 ID	파일 내부 중복 없음. 파일 자체의 고유 ID나 해시가 아님
date	날짜·시간	파일 이벤트 발생 시각	파일 생성·최종 수정 시각을 뜻하는 컬럼은 아님
user	문자열	파일 이벤트를 수행한 것으로 해석되는 사용자	고유 사용자 264명
pc	문자열	파일 이벤트가 발생한 PC	고유 PC 956대
filename	문자열	이벤트 대상 파일명	대표 값은 SAMPLE01.doc처럼 이름과 확장자로 구성. 파일명만으로 동일 파일 여부를 확정할 수 없음
content	문자열	파일 형식 관련 헤더 표현과 텍스트·주제 키워드	대표 행에서 하이픈으로 구분된 16진수 점두부 뒤에 단어들이 이어짐. 원본 바이너리 전체나 해시로 해석하지 않음

확인한 데이터 특성

확장자	이벤트 건수
.doc	285,897
.pdf	87,953
.txt	23,033
.jpg	22,895
.zip	22,829
.exe	2,974

위 수치는 고유 파일 개수가 아니라 해당 확장자가 기록된 이벤트 수다.

분석 시 활용: 파일 이벤트 빈도, 확장자별 사용 패턴, 장치 연결 전후의 파일 활동 집중, 사용자별 파일 내용 특성 변화.

해석상 주의: 현재 파일에는 activity, 파일 크기, 원본·대상 경로, 장치 ID, 이동식 매체 방향 플래그가 없다. 열기·쓰기·복사·삭제를 개별 행에 임의로 부여하거나, 건수를 데이터 반출 바이트 수로 환산하면 안 된다.

4.4. http.csv — 웹 접근 로그

의미: 사용자의 웹 URL 접근과 관련된 이벤트다. 네트워크 패킷 전체나 HTTP 요청·응답 전문을 담은 파일은 아니다.

컬럼명	권장 자료형	컬럼별 의미	값의 형태 / 확인 사항
id	문자열	웹 접근 이벤트 ID	파일 내부 중복 없음
date	날짜·시간	웹 접근이 기록된 시각	접속 종료 시각이나 체류시간 정보는 없음
user	문자열	웹 접근에 연결된 사용자	고유 사용자 1,000명
pc	문자열	웹 접근이 발생한 PC	고유 PC 1,000대
url	문자열	접근한 웹 주소	스킴·호스트·경로 등으로 분해 가능. 제공된 1,422,900행의 스킴은 모두 http

컬럼명	권장 자료형	컬럼별 의미	값의 형태 / 확인 사항
content	문자열	접근 대상 웹 콘텐츠의 텍스트·주제 키워드 표현으로 해석	대표 행은 공백으로 구분된 단어 나열. HTML 원문, 업로드 본문 또는 다운로드 파일 전체라고 단정할 수 없음

분석 시 활용: 도메인별 접근 빈도, 사용자별 새로운 도메인 접근, 시간대별 패턴, URL 경로와 내용 키워드 변화.

해석상 주의: HTTP 메서드, 상태 코드, 전송량, 목적지 IP, 업로드·다운로드 구분이 없다. URL 접근만으로 정보 업로드나 유출을 확정할 수 없다. 모든 스캔이 http라는 결과도 이 샘플의 관찰값이며, 원래 환경에 HTTPS 사용이 없었다는 증거는 아니다.

4.5. logon.csv — 로그인·로그오프 로그

의미: 사용자가 PC에 로그인하거나 로그오프한 이벤트를 기록한다. 한 행은 하나의 이벤트이며, 로그인부터 로그오프까지의 완성된 세션이 아니다.

컬럼명	권장 자료형	컬럼별 의미	값의 형태 / 확인 사항
id	문자열	로그인·로그오프 이벤트 ID	파일 내부 중복 없음
date	날짜·시간	로그인 또는 로그오프 시각	MM/DD/YYYY HH:mm:ss
user	문자열	로그인·로그오프한 사용자 계정	고유 사용자 1,000명
pc	문자열	로그인·로그오프 대상 PC	고유 PC 1,003대
activity	범주형 문자열	세션 관련 행위 종류	Logon: 로그인, 470,591건 / Logoff: 로그오프, 384,268건

분석 시 활용: 사용자별 첫 로그인·마지막 로그오프, 시간대별 활동, 평소와 다른 PC 사용, 세션 추정.

해석상 주의: 성공실패 상태, 원격·로컬 구분, 인증 방식, 세션 ID는 없다. 로그인 실패 탐지용 데이터라고 볼 수 없다. Logon과 Logoff의 건수가 다르므로, 누락·연속 로그인·날짜를 넘는 세션을 고려해야 하며 단순히 인접한 두 행을 짝지으면 안 된다.

4.6. psychometric.csv — 직원 성격 특성 데이터

의미: 직원별 성격 5요인인 OCEAN 점수를 제공하는 속성 데이터다.

컬럼명	권장 자료형	컬럼별 의미	확인된 값 / 해석상 주의
employee_name	문자열	직원 이름	1,000개의 고유 이름. 연결에는 이름보다 user_id 사용
user_id	문자열	직원 사용자 계정 ID	1,000개의 고유 ID. 활동 로그의 user, LDAP의 user_id와 연결
O	정수	Openness: 개방성. 새로운 경험·아이디어에 대한 수용성, 호기심 등	관찰 범위 10~50
C	정수	Conscientiousness: 성실성. 계획성·책임감·자기관리 등	관찰 범위 10~50
E	정수	Extraversion: 외향성. 사교성·활동성·대인 교류 성향 등	관찰 범위 10~50
A	정수	Agreeableness: 우호성 / 친화성. 협조·배려·타인에 대한 신뢰 성향 등	관찰 범위 10~50
N	정수	Neuroticism: 신경성. 스트레스·부정적 정서에 대한 민감성 등	관찰 범위 14~49. 정서적 안정성과 같은 방향의 점수로 해석하지 않음

해석상 주의: 위 범위는 실제 관찰된 최솟값·최댓값이며, 검사에서 허용하는 이론적 범위가 확인된 것은 아니다. 점수를 백분율, 임상 진단, 악성 사용자 라벨 또는 보안 위험 점수로 해석하지 않는다. 보안 분석에서는 행동 로그에 덧붙이는 사용자 속성으로 검토할 수 있으나, 이 점수만으로 악성 행위를 판정할 근거는 없다.

4.7. LDAP/2009-12.csv — 직원 계정·조직 정보

의미: LDAP는 Lightweight Directory Access Protocol의 약자다. 직원 디렉터리·조직 정보 테이블이다. 파일은 2009년 12월 기준 스냅샷으로 해석한다.

컬럼명	권장 자료형	컬럼별 의미	확인 사항 및 주의점
employee_name	문자열	직원 이름	고유 값 1,000개. 심리측정 데이터와 같은 user_id의 이름이 모두 일치
user_id	문자열	직원 사용자 계정 ID	고유 값 1,000개. 이 스냅샷의 기본키로 사용 가능
email	문자열	직원의 등록 이메일 주소	고유 값 1,000개. 모두 dtaa.com 도메인
role	범주형 문자열	직무·직책	42종. 예: SoftwareEngineer, ITAdmin. 시스템 접근 권한이나 IAM 역할 목록으로 단정하지 않음
business_unit	범주형 문자열	상위 사업 조직 코드로 해석	모든 직원의 값이 1. 수량·점수가 아니며, 사업 조직 명칭은 제공되지 않음
functional_unit	범주형 문자열, 빈 값 허용	기능별 조직·본부 구분으로 해석	번호·조직명 형태. 비어 있지 않은 값 6종, 빈 값 2건
department	범주형 문자열, 빈 값 허용	부서 구분	번호·부서명 형태. 비어 있지 않은 값 22종, 빈 값 14건
team	범주형 문자열, 빈 값 허용	팀 구분	번호·팀명 형태. 비어 있지 않은 값 38종, 빈 값 127건
supervisor	문자열, 빈 값 허용	직속 상사 이름으로 해석	사용자 ID가 아니라 이름. 비어 있지 않은 상사 이름 67개, 빈 값 1건

분석 시 활용: 직무·부서·팀이 유사한 직원 사이의 행위 비교, 조직 단위 집계, 상사 관계 분석, 등록 이메일을 이용한 사내 주소 매핑.

해석상 주의

- business_unit → functional_unit → department → team은 상위 사업 조직에서 하위 팀으로 이어지는 계층으로 해석할 수 있다. 정확한 조직 체계는 별도 명세로 확인해야 한다.
- 번호 - 이름에서 번호만 떼어 전사적으로 유일한 코드로 간주하지 않는다. 조직별 지역 코드일 수 있으므로 원문 전체와 상위 조직을 보존한다.
- 일부 계층이 비어 있는 원인은 미배정·상위 직책·수집 누락 등으로 나뉠 수 있지만, 현재 파일만으로 어느 원인인지 확정할 수 없다.
- 비어 있지 않은 모든 supervisor 값은 이 스냅샷의 employee_name과 매칭되며, 직원 이름 중복은 없다. 따라서 현재 파일에서는 이름으로 상사를 찾고 그 상사의 user_id를 가져오는 방식으로 관계를 구성할 수 있다.
- 이 파일에는 2010~2011년의 인사 변동이 직접 들어 있지 않다. 미래 로그에 결합하더라도 그 시점의 실제 부서·직책이라는 보장은 없다.

5. 파일 간 연결 관계

연결 대상	연결 키/방식	이번 검사 결과	적용 시 주의
활동 로그 ↔ LDAP	로그의 user = LDAP의 user_id	5개 활동 로그의 모든 사용자 ID가 LDAP에 존재	로그 여러 행 : 직원 1행 관계. 2009-12 기준 속성임을 보존
활동 로그 ↔ 심리측정	로그의 user = 심리측정의 user_id	5개 활동 로그의 모든 사용자 ID가 심리측정 파일에 존재	직원 단위 속성이므로 이벤트마다 복제되더라도 독립 관측값이 늘어난 것은 아님
LDAP ↔ 심리측정	user_id	두 파일의 사용자 1,000명이 모두 일치하며 이름도 일치	이번 파일에서는 일대일 연결 가능
이메일 ↔ LDAP 등록 주소	from, 분리한 to·cc·bcc ↔ LDAP의 email	LDAP 등록 주소는 모두 dtaa.com	복수 주소는 분리 후 연결. 전체 수신자 주소의 등록 여부는 이번 검사 범위에 포함하지 않음
LDAP 직원 ↔ 상사	supervisor = 다른 행의 employee_name	비어 있지 않은 상사 이름은 모두 매칭	매칭 후 상사의 user_id로 관계를 저장하는 편이 안정적
활동 로그 ↔ 다른 활동 로그	user·pc·시간 순서 또는 시간 구간	해당 필드가 모든 활동 로그에 존재	id로 서로 다른 종류의 이벤트를 조인하지 않음. 연결·세션 매칭 자체는 이번 분석에서 수행하지 않음

예를 들어 ‘로그인 → 장치 연결 → 파일 이벤트 → 장치 해제’의 흐름을 살펴보려면 동일 사용자의 동일 PC에서 발생한 이벤트를 시간 순서로 정렬한다. 시간적 근접성은 연관성을 살펴보는 근거이며, 동일 세션·동일 장치·유출 행위가 증명된 것은 아니다.

6. 데이터 품질 확인 결과

확인 항목	결과
CSV 구조	7개 파일 모두 헤더와 필드 수가 다른 데이터 행 0건
이벤트 ID 중복	5개 활동 로그 각각에서 id 중복 0건
날짜 파싱	5개 활동 로그에서 지정 형식으로 변환할 수 없는 값 0건
날짜 정렬	각 활동 로그에서 앞 행보다 시간이 이른 행 0건. 같은 시각의 이벤트는 허용
숫자 변환	size, attachments, O, C, E, A, N의 정수 변환 실패 0건
활동 로그의 빈 값	이메일의 cc, bcc에서만 관찰. 나머지 활동 로그 컬럼의 빈 값 0건
심리측정 빈 값	모든 컬럼에서 0건
LDAP 빈 값	functional_unit 2건, department 14건, team 127건, supervisor 1건
직원 연결	활동 로그의 사용자 ID가 LDAP·심리측정에 모두 존재
악성 여부 컬럼	분석한 7개 파일에 악성 여부를 나타내는 명시적 정답 컬럼 없음

빈 값은 비어 있거나 공백만 있는 문자열을 기준으로 계산했다. 문자열 NULL 등의 별도 결측 표기 탐지나 전체 행 중복 검사는 수행하지 않았다. ID 중복 검사는 파일별로 수행했으며, 파일 간 전역 유일성 검사가 아니다.

7. 프로젝트 적용 시 먼저 정할 사항

- 로그 시간대와 근무시간 기준: date에는 시간대가 없고, 근무표·휴일 달력도 없다. 특정 시간대를 곧바로 비정상 근무시간으로 지정하기 전에 분석 기준을 정한다.
- 이메일 크기·방향과 파일 작업 의미: size의 단위·첨부 포함 여부, 이메일의 발송·수신 구분, 파일 이벤트의 작업·전송 방향은 릴리스 설명서 또는 제공처의 데이터 사전으로 확인한다.
- 조직 정보의 적용 시점: 이번에 분석한 LDAP는 2009-12 파일이다. 월별 인사 변동을 반영하려면 다른 월 파일도 확인하고, 각 스냅샷의 실제 기준일·효력 범위에 따라 이벤트에 연결한다.
- 정답 데이터와 샘플링 범위: 이 7개 파일의 행위만으로 정상·악성 라벨을 확정할 수 없다. 지도학습이나 탐지 성능 평가에는 현재 샘플과 대응하는 정답·추출 기준이 필요하다.

문서 끝 - 데이터 해석 시 각 로그의 방향, 시간대, 누락 가능성과 정답 라벨 부재를 고려해야 한다.